كلية العلوم التطبيقية – ورزازات
ⵜⴰⵖⵍⵓⵍⵜ ⵏ ⵜⵙⵙⵏⴰⵢⵉⵏ ⵜⵉⵎⵙⵙⵓⵔⵉⵏ - ⵡⵓⵔⵣⴰⵣⴰⵜ
FACULTE DES SCIENCES APPLIQUEES - OUARZAZATE

Master Intelligence Artificielle et Applications

Rapport de projet

Détection précoce du sepsis par réseau LSTM optimisé par Évolution Différentielle

Comparaison avec la recherche aléatoire et une configuration manuelle
sur les données PhysioNet/CinC Challenge 2019

Réalisé par :

Chaymae Al-aissaoui
Ikram El Ghidouni
Sohayeb Gasmi

Encadré par :

Aissam Hadri

Année universitaire : 2025/2026

Remerciements

Au terme de ce projet, nous tenons à exprimer notre profonde et sincère gratitude à Dr. Hadri Aissam notre professeur dans le cadre du Master Intelligence Artificielle et Applications, à la Faculté des Sciences Appliquées de Ouarzazate.

Nous souhaitons le remercier chaleureusement pour la qualité de son enseignement tout au long de ce semestre, ainsi que pour son engagement, sa disponibilité et les efforts qu'il a constamment déployés afin de nous accompagner dans notre apprentissage. Ses explications, ses conseils précieux et sa volonté de partager ses connaissances nous ont permis de renforcer nos compétences, d'approfondir notre compréhension des technologies du développement web et de mettre en pratique les notions acquises à travers la réalisation de ce projet.

Nous lui sommes particulièrement reconnaissants pour sa contribution à notre formation, son soutien pédagogique et l'importance qu'il accorde à notre progression académique et professionnelle. Son enseignement a constitué un apport précieux dans notre parcours et nous a permis d'aborder ce travail avec davantage de connaissances, de méthode et de confiance.

Nous lui adressons nos plus vifs remerciements et lui exprimons toute notre reconnaissance pour son dévouement, son investissement et la qualité de l'enseignement dont nous avons bénéficié durant ce semestre.

Résumé

Le sepsis est une dysfonction d'organe menaçant le pronostic vital, dont la prise en charge précoce conditionne l'issue du patient. Ce travail étudie la prédiction précoce du sepsis en unité de soins intensifs à partir des données du PhysioNet/Computing in Cardiology Challenge 2019 (40 336 patients, 1 552 210 heures d'observation, 34 variables temporelles). Un réseau récurrent à mémoire longue (LSTM) estime, heure par heure, la probabilité que l'étiquette de sepsis soit positive (6 heures avant l'apparition clinique). Ses six hyperparamètres (taille cachée, nombre de couches, dropout, taux d'apprentissage, décroissance des poids, longueur de fenêtre) sont optimisés par une Évolution Différentielle (DE) implémentée entièrement dans ce travail, puis comparés à une recherche aléatoire et à une configuration manuelle, *à budget égal* (220 entraînements).

Après validation de l'algorithme sur quatre fonctions de référence (Sphere, Rosenbrock, Rastrigin, Ackley), où la DE surpasse systématiquement la recherche aléatoire, l'optimisation des hyperparamètres montre que la DE trouve la meilleure configuration sur la validation (AUPRC de 0,0952 contre 0,0908 pour la recherche aléatoire et 0,0905 pour la configuration manuelle) et concentre bien davantage ses essais dans la zone performante (15,9 % des essais dépassent la configuration manuelle, contre 0,5 % pour la recherche aléatoire). En revanche, l'évaluation finale sur le jeu de test, avec trois graines et un bootstrap au niveau patient, ne met en évidence *aucune différence statistiquement démontrable* entre les trois approches (AUPRC d'ensemble $\approx$ 0,134 ; AUROC $\approx$ 0,85). Les intervalles de confiance des différences appariées contiennent zéro. Une analyse au niveau patient révèle que la DE offre une sensibilité plus élevée (53,0 % contre 35,5 %), au prix d'un taux d'alarmes plus important, ce qui reflète un autre point de fonctionnement plutôt qu'une meilleure capacité de discrimination. Les limites (budget réduit, objectif estimé par un entraînement court, optimum au bord de l'espace de recherche) et des pistes d'amélioration sont discutées.

Mots-clés : sepsis, détection précoce, LSTM, évolution différentielle, optimisation d'hyperparamètres, recherche aléatoire, PhysioNet, AUPRC.

Abstract

Sepsis is a life-threatening organ dysfunction for which early recognition is critical. This work addresses hourly early prediction of sepsis in intensive care using the PhysioNet/Computing in Cardiology Challenge 2019 data (40,336 patients). A Long Short-Term Memory (LSTM) network is tuned by a Differential Evolution (DE) algorithm implemented from scratch, and compared with random search and a manual configuration under an identical budget of 220 trainings. DE reaches the best validation AUPRC (0.0952 vs. 0.0908 and 0.0905) and concentrates its trials in high-performing regions, but the final test evaluation (three seeds, patient-level bootstrap) shows no statistically demonstrable difference between the three approaches (ensemble AUPRC ≈ 0.134, AUROC ≈ 0.85). At the patient level, DE yields a higher sensitivity at the price of more alarms. Limitations and perspectives are discussed.

Keywords: sepsis, early prediction, LSTM, differential evolution, hyperparameter optimization, random search, AUPRC.

Table des matières

Remerciements i

Résumé ii

Abstract iii

Table des figures v

Liste des tableaux vi

Liste des abréviations et notations viii

1 Introduction générale 1

1.1 Contexte clinique 1

1.2 Détection précoce par apprentissage automatique 1

1.3 Problématique 1

1.4 Question de recherche et objectifs 2

1.5 Organisation du rapport 2

2 Fondements théoriques **3**
2.1 Réseaux LSTM . . . 3
2.2 Optimisation d'hyperparamètres . . . 3
2.3 Évolution Différentielle . . . 3
2.4 Métriques d'évaluation . . . 4

3 Données et prétraitement **5**
3.1 Jeu de données . . . 5
3.2 Analyse exploratoire . . . 5
3.3 Prétraitement . . . 8

4 Méthodologie expérimentale **9**
4.1 Architecture du LSTM et entraînement . . . 9
4.2 Espace de recherche . . . 9
4.3 Les trois bras comparés . . . 10
4.4 Fonction objectif et protocole de recherche . . . 10
4.5 Protocole d'évaluation finale . . . 10

5 Validation de la DE sur des fonctions de référence **12**

6 Résultats **15**
6.1 Hyperparamètres trouvés . . . 15
6.2 Dynamique de la recherche . . . 15
6.3 Importance des hyperparamètres . . . 18
6.4 Évaluation finale sur le jeu de test . . . 19
6.4.1 Résultats moyens sur trois graines . . . 19
6.4.2 Modèle d'ensemble . . . 20
6.4.3 Surapprentissage et variabilité entre graines . . . 21
6.5 Évaluation au niveau du patient . . . 21
6.6 Significativité statistique . . . 22

7 Discussion **24**
7.1 Ce que montrent les résultats . . . 24
7.2 Explications possibles . . . 24
7.3 Limites de l'étude . . . 25
7.4 Perspectives . . . 25

Conclusion générale **26**

Bibliographie **27**

Bibliographie **27**

A Valeurs manquantes par variable **30**

B Résultats détaillés des fonctions de référence **32**

C Résultats détaillés par graine **33**

D Configuration retenue **34**

Table des figures

3.1 Déséquilibre des classes et distribution des durées de séjour. 5
3.2 Taux de valeurs manquantes par variable. 6
3.3 Trajectoires moyennes des signes vitaux autour de l'instant de début du sepsis. 6
3.4 Matrice de corrélation entre variables temporelles (observations appariées). 7

5.1 Courbes de convergence des variantes de DE et de la recherche aléatoire sur les fonctions de référence. 13
5.2 Évolution de la population de DE sur une fonction de Rastrigin en dimension 2 (NP = 24). 13
5.3 Sensibilité de la DE : (haut) aux paramètres F et CR ; (bas) à la taille de population NP à budget fixe. 14

6.1 Progression de la recherche : chaque point est une évaluation, les courbes donnent la meilleure valeur obtenue ; à droite, gain par rapport à la configuration manuelle. 16
6.2 Diagnostics de la DE : AUPRC de la population, diversité, taux de succès des essais et distribution par génération. 17
6.3 Trajectoires des hyperparamètres au cours des générations de la DE. . . 18
6.4 Relation entre chaque hyperparamètre et l'AUPRC de validation pour les essais de la DE et de la recherche aléatoire. 18
6.5 Coordonnées parallèles des meilleurs essais et fonction de répartition empirique (ECDF) de l'AUPRC de validation. 19
6.6 Courbes ROC et précision–rappel sur le test, et courbe de calibration des trois modèles. 20
6.7 Matrices de confusion, distribution des scores par classe et sensibilité des métriques au seuil de décision. 21
6.8 Courbes d'apprentissage (perte d'entraînement et AUPRC de validation) et AUPRC de test par graine. 21

6.9 Distribution des délais d'alerte (valeurs tronquées à $[-30, 100]$ heures) et courbe d'alerte précoce. 22
6.10 Distributions bootstrap des AUPRC et AUROC et des différences appariées. 23

Liste des tableaux

3.1 Résumé du jeu de données PhysioNet/CinC 2019 (hôpitaux A et B). . . 5
3.2 Comparaison des variables cliniques selon le statut (médiane [intervalle interquartile]) ; test de Mann–Whitney. 7
3.3 Découpage des patients en entraînement, validation et test (stratifié sur la survenue du sepsis). 8

4.1 Espace de recherche des hyperparamètres (tel qu'implémenté). 9
4.2 Paramètres de l'exécution (mode « fast » du notebook). 11

5.1 Fonctions de référence ($D = 10$, $NP = 50$, $G = 300$, 5 répétitions) : valeur finale moyenne de f (rang entre parenthèses) et rang moyen. . . 12

6.1 Meilleurs hyperparamètres obtenus par chaque méthode. 15
6.2 Meilleure AUPRC de validation atteinte en fonction du budget consommé. 16
6.3 Statistiques de qualité des 220 essais de chaque méthode (AUPRC de validation, protocole de recherche). 16
6.4 Historique de la population de DE par génération (AUPRC de validation $= 1 - f$). 17
6.5 Corrélation de Spearman entre chaque hyperparamètre et l'AUPRC de validation. 19
6.6 Résultats sur le jeu de test : métriques de classement (moyenne ± écart-type sur 3 graines). 19
6.7 Résultats sur le jeu de test : métriques au seuil choisi sur la validation (moyenne ± écart-type sur 3 graines). 20
6.8 Résultats sur le jeu de test du modèle d'ensemble (moyenne des probabilités calibrées des 3 graines). 20
6.9 Évaluation au niveau du patient (440 patients septiques du jeu de test). 22
6.10 Intervalles de confiance à 95 % par bootstrap au niveau patient ($B = 200$) sur le test (modèle d'ensemble). 23

6.11 Différences appariées par bootstrap (Δ) entre DE et les deux autres méthodes. 23

A.1 Taux de valeurs manquantes par variable (ensemble des 40 336 patients). 30

B.1 Résultats détaillés sur les fonctions de référence (valeur finale de f sur 5 répétitions). 32

C.1 Résultats sur le jeu de test pour chaque graine d'entraînement. 33

Liste des abréviations et notations

AUPRC	Aire sous la courbe précision–rappel (*Area Under the Precision-Recall Curve*)
AUROC	Aire sous la courbe ROC
CinC	*Computing in Cardiology*
CR	Taux de croisement (*Crossover Rate*) de la DE
DE	Évolution Différentielle (*Differential Evolution*)
F	Facteur de mutation de la DE
G	Nombre de générations de la DE
IC	Intervalle de confiance
jDE	Variante auto-adaptative de la DE
LSTM	Mémoire longue à court terme (*Long Short-Term Memory*)
MCC	Coefficient de corrélation de Matthews
NP	Taille de la population de la DE
RS	Recherche aléatoire (*Random Search*)
SOFA	*Sequential Organ Failure Assessment*
T	Longueur de la fenêtre temporelle (heures)
lr, wd	Taux d'apprentissage, décroissance des poids (*weight decay*)

Chapitre 1

Introduction générale

1.1 Contexte clinique

Le sepsis est défini par le consensus Sepsis-3 comme une dysfonction d'organe menaçant le pronostic vital, causée par une réponse dérégulée de l'hôte à une infection [4]. Son poids sanitaire est considérable : selon l'étude *Global Burden of Disease*, on estime à 48,9 millions le nombre de cas incidents et à 11,0 millions le nombre de décès liés au sepsis dans le monde en 2017, soit 19,7 % de l'ensemble des décès [5]. Les données observationnelles associent un délai plus long avant l'administration d'antibiotiques et la complétion d'un ensemble de soins à une mortalité hospitalière plus élevée [6], ce qui motive le développement d'outils d'alerte précoce. Il convient toutefois de rappeler qu'il s'agit d'une association et non d'une preuve de causalité.

1.2 Détection précoce par apprentissage automatique

Pour comparer les approches de détection précoce sur des bases communes, le *PhysioNet/Computing in Cardiology Challenge 2019* a mis à disposition des données horaires de patients de soins intensifs, étiquetées selon les critères Sepsis-3, ainsi qu'une fonction d'utilité clinique récompensant les prédictions précoces et pénalisant les alarmes tardives, manquées ou fausses [1, 2]. Les auteurs concluent que des approches variées parviennent à prédire le sepsis plusieurs heures avant la reconnaissance clinique, mais que la généralisation entre systèmes hospitaliers reste difficile [1].

1.3 Problématique

Les réseaux récurrents de type LSTM [7] sont adaptés aux séries temporelles cliniques irrégulières, mais leurs performances dépendent fortement de leurs hyperparamètres (taille, profondeur, régularisation, taux d'apprentissage, longueur de fenêtre). Le réglage manuel est subjectif et la recherche exhaustive est trop coûteuse, chaque évaluation exigeant l'entraînement complet d'un réseau. La fonction à optimiser est une *boîte noire* : non dérivable (variables entières), bruitée (graine, mini-lots) et potentiellement multimodale. Les méta-heuristiques évolutionnaires, et en particulier l'Évolution Différentielle (DE) [8, 10], constituent une réponse naturelle à ce type de problème.

1.4 Question de recherche et objectifs

La question centrale est la suivante : *la DE fournit-elle au LSTM de meilleures performances que (a) une configuration manuelle raisonnable et (b) une recherche aléatoire disposant du même nombre d'essais ?* Les objectifs sont :

(i) implémenter la DE (cinq variantes, dont l'auto-adaptative jDE [9]) et valider son comportement sur des fonctions de référence ;

(ii) construire un LSTM de prédiction horaire du sepsis, avec un prétraitement strictement causal et une séparation des données par patient ;

(iii) comparer trois « bras » (manuel, recherche aléatoire, DE) à budget de calcul identique, en validation puis sur un jeu de test jamais utilisé pour la sélection ;

(iv) quantifier la robustesse des conclusions (plusieurs graines, bootstrap au niveau patient, différences appariées).

1.5 Organisation du rapport

Le chapitre 2 présente les fondements théoriques. Le chapitre 3 décrit les données et le prétraitement. Le chapitre 4 détaille la méthodologie expérimentale. Le chapitre 5 valide l'implémentation de la DE sur des fonctions de référence. Le chapitre 6 présente les résultats, discutés au chapitre 7. Une conclusion générale clôt le rapport.

Chapitre 2

Fondements théoriques

2.1 Réseaux LSTM

Le LSTM [7] introduit un état de cellule c_t contrôlé par des portes, qui atténue le problème de disparition du gradient des réseaux récurrents classiques. Pour une entrée x_t et un état caché h_{t-1} :

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i), \qquad f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f), \tag{2.1}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o), \qquad \tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c), \tag{2.2}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \qquad h_t = o_t \odot \tanh(c_t), \tag{2.3}$$

où σ est la sigmoïde et $\odot$ le produit élément par élément. La formulation additive de c_t permet au gradient de se propager sur de longues séquences.

2.2 Optimisation d'hyperparamètres

Soit $\mathbf{x} \in \mathcal{X}$ un vecteur d'hyperparamètres et $f(\mathbf{x})$ une mesure d'erreur de validation du modèle entraîné avec $\mathbf{x}$. On cherche $\mathbf{x}^\star = \arg\min_{\mathbf{x}\in\mathcal{X}} f(\mathbf{x})$. La recherche aléatoire [11] échantillonne $\mathcal{X}$ uniformément ; elle est simple, parallélisable et souvent plus efficace que la grille lorsque peu d'hyperparamètres influencent réellement la performance. Les approches séquentielles de type bayésien [12, 13] constituent une autre famille, non étudiée ici mais évoquée en perspectives.

2.3 Évolution Différentielle

La DE [8] fait évoluer une population de NP vecteurs $\mathbf{x}_i^{(g)} \in \mathbb{R}^D$ par trois opérateurs, revue en détail dans [10].

Mutation.. Pour chaque individu $\mathbf{x}_i$, un vecteur donneur $\mathbf{v}_i$ est construit. Pour la stratégie classique *rand/1* :

$$\mathbf{v}_i = \mathbf{x}_{r_1} + F\,(\mathbf{x}_{r_2} - \mathbf{x}_{r_3}), \tag{2.4}$$

avec r_1, r_2, r_3 distincts et différents de i. La stratégie *current-to-best/1*, utilisée pour l'optimisation du LSTM, s'écrit

$$\mathbf{v}_i = \mathbf{x}_i + F\,(\mathbf{x}_{\text{best}} - \mathbf{x}_i) + F\,(\mathbf{x}_{r_1} - \mathbf{x}_{r_2}). \tag{2.5}$$

Les autres variantes implémentées sont *best/1*, *rand/2* et la version auto-adaptative jDE.

Croisement binomial.. Le vecteur d'essai $\mathbf{u}_i$ reprend chaque composante du donneur avec la probabilité CR (au moins une composante est toujours reprise) :

$$u_{i,j} = \begin{cases} v_{i,j} & \text{si } \text{rand}_j \le CR \text{ ou } j = j_{\text{rand}}, \\ x_{i,j} & \text{sinon.} \end{cases} \tag{2.6}$$

Sélection gloutonne.. L'individu d'essai remplace le parent s'il n'est pas moins bon : $\mathbf{x}_i^{(g+1)} = \mathbf{u}_i$ si $f(\mathbf{u}_i) \le f(\mathbf{x}_i^{(g)})$, sinon $\mathbf{x}_i^{(g)}$.

jDE.. Dans la variante jDE [9], chaque individu porte ses propres F_i et CR_i, régénérés avant chaque mutation avec une probabilité $\tau_1 = \tau_2 = 0{,}1$.

Le budget total est $N_{\text{eval}} = NP\,(G+1)$ évaluations de la fonction objectif.

2.4 Métriques d'évaluation

Le problème est très déséquilibré (environ 1,8 % de lignes positives). L'exactitude est donc trompeuse : un modèle prédisant toujours « pas de sepsis » atteindrait environ 98 %. Nous retenons principalement l'*AUPRC* (précision moyenne), plus informative que l'AUROC en présence d'un fort déséquilibre [18, 19], dont la valeur de référence d'un classifieur aléatoire est la prévalence ($\approx 0{,}018$). Avec TP, FP, TN, FN pour un seuil τ :

$$\text{Précision} = \frac{TP}{TP+FP}, \qquad \text{Rappel} = \frac{TP}{TP+FN}, \qquad \text{Spécificité} = \frac{TN}{TN+FP}, \tag{2.7}$$

$$F_1 = \frac{2\,\text{Précision}\cdot\text{Rappel}}{\text{Précision}+\text{Rappel}}, \tag{2.8}$$

$$\text{MCC} = \frac{TP\cdot TN - FP\cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}. \tag{2.9}$$

Le MCC est une mesure robuste en cas de classes déséquilibrées [20]. Le score de Brier [21] mesure la qualité des probabilités : $\frac{1}{N}\sum_n (\hat{p}_n - y_n)^2$. Une calibration de Platt [22] est apprise sur la validation uniquement ; elle est monotone et ne modifie donc ni l'AUROC ni l'AUPRC.

Chapitre 3

Données et prétraitement

3.1 Jeu de données

Les données proviennent du PhysioNet/CinC Challenge 2019 [1, 2, 3], composé des ensembles d'entraînement des hôpitaux A et B. Chaque patient correspond à un fichier `.psv` avec une ligne par heure de séjour et 40 colonnes : 8 signes vitaux, 26 analyses de laboratoire et 6 variables statiques (âge, sexe, unités de soins, délai d'admission, durée de séjour en soins intensifs), plus l'étiquette `SepsisLabel`. Au total, 34 variables sont temporelles. Le tableau 3.1 résume la composition de la base.

Table 3.1: Résumé du jeu de données PhysioNet/CinC 2019 (hôpitaux A et B).

Hôpital	Patients	Septiques	% pat.	Heures	Lignes +	% lignes	Séjour moy. (h)	Méd. (h)
A	20 336	1 790	8,80 %	790 215	17 136	2,17 %	38,9	39
B	20 000	1 142	5,71 %	761 995	10 780	1,41 %	38,1	38
Total	40 336	2 932	7,27 %	1 552 210	27 916	1,80 %	38,5	38

L'étiquette est construite selon Sepsis-3 : si t_{sepsis} désigne l'instant clinique de début, $\texttt{SepsisLabel}(t) = 1$ pour $t \geq t_{\text{sepsis}} - 6\,\text{h}$ [1]. Une alerte au premier « 1 » correspond donc à une prédiction d'au moins 6 heures avant le sepsis clinique. La prévalence est de 7,27 % au niveau patient mais de seulement 1,80 % au niveau des lignes horaires (figure 3.1).

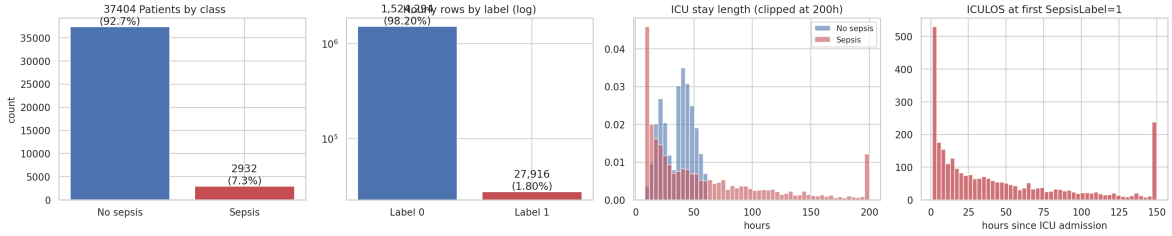


Figure 3.1: Déséquilibre des classes et distribution des durées de séjour.

3.2 Analyse exploratoire

Valeurs manquantes.. Les variables de laboratoire sont extrêmement lacunaires (plus de 90 % de valeurs manquantes pour la plupart, jusqu'à 99,8 % pour la bilirubine directe), tandis que les signes vitaux sont mieux renseignés (par exemple 9,9 % de

manquants pour la fréquence cardiaque, mais 66,2 % pour la température) ; voir la figure 3.2 et le tableau A.1 en annexe. Cette absence de mesure est elle-même informative : un clinicien prescrit un lactate lorsqu'il suspecte un sepsis. Cette observation justifie l'ajout de masques d'observation (section 3.3).

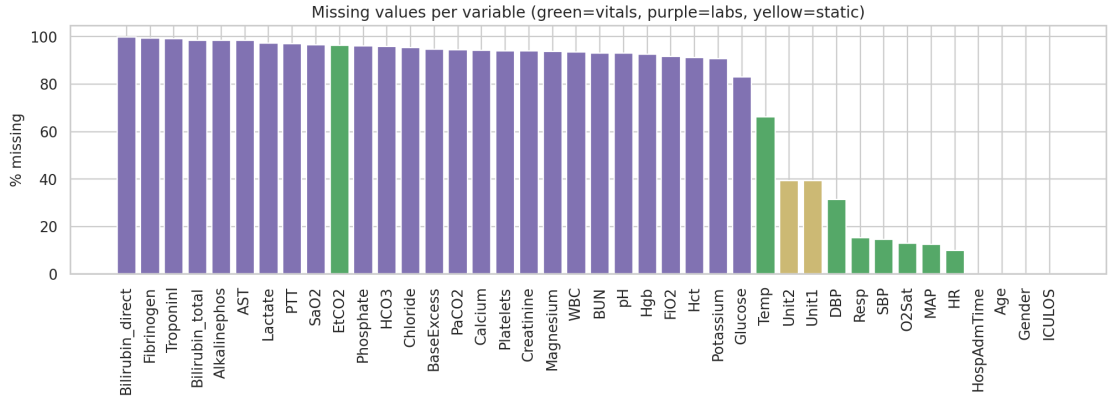


Figure 3.2: Taux de valeurs manquantes par variable.

Différences entre classes.. Le tableau 3.2 compare les patients avec et sans sepsis. Les patients septiques présentent, en médiane, une fréquence cardiaque, une température, une fréquence respiratoire, une leucocytose, une créatininémie et une urémie plus élevées, ce qui est cohérent avec la physiopathologie du sepsis. Certains écarts, bien que très significatifs statistiquement en raison de la taille de l'échantillon, sont de faible amplitude (par exemple la saturation en oxygène : 97,4 contre 97,6). Le lactate et l'âge ne diffèrent pas significativement.

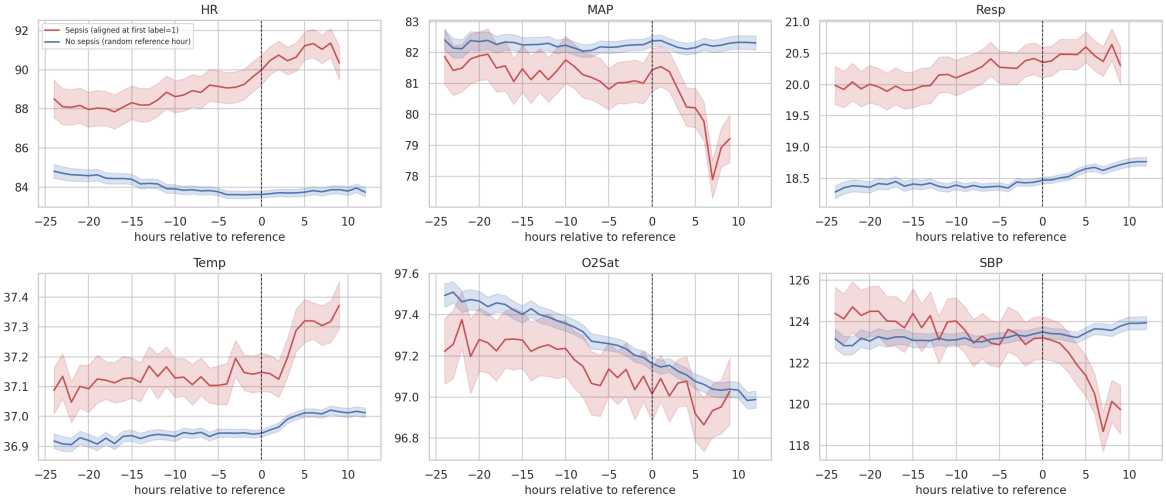


Figure 3.3: Trajectoires moyennes des signes vitaux autour de l'instant de début du sepsis.

Table 3.2: Comparaison des variables cliniques selon le statut (médiane [intervalle interquartile]) ; test de Mann–Whitney.

Variable	Sans sepsis	Sepsis	p
HR	82,8 [73,2–92,6]	88,4 [77,5–99,3]	$< 10^{-3}$
O2Sat	97,4 [96,1–98,5]	97,6 [96,1–98,8]	$< 10^{-3}$
Temp	36,8 [36,5–37,2]	37,0 [36,6–37,5]	$< 10^{-3}$
SBP	121,4 [110,5–134,8]	119,7 [107,9–132,7]	$< 10^{-3}$
MAP	80,9 [73,7–90,2]	79,3 [72,2–87,8]	$< 10^{-3}$
DBP	63,0 [56,5–70,8]	61,5 [55,1–68,9]	$< 10^{-3}$
Resp	18,1 [16,4–20,2]	19,2 [16,8–22,2]	$< 10^{-3}$
EtCO2	33,2 [28,5–37,5]	32,4 [27,7–36,3]	0,002
Lactate	1,7 [1,2–2,4]	1,7 [1,2–2,6]	0,167
WBC	10,1 [7,6–13,1]	11,5 [8,5–15,2]	$< 10^{-3}$
Creatinine	0,9 [0,7–1,3]	1,1 [0,8–1,8]	$< 10^{-3}$
Platelets	191,7 [143,0–251,7]	186,1 [126,5–256,0]	$< 10^{-3}$
BUN	16,0 [11,3–25,0]	21,2 [13,7–35,4]	$< 10^{-3}$
Glucose	124,2 [108,0–144,7]	129,5 [112,0–152,0]	$< 10^{-3}$
Age	63,0 [51,0–74,0]	64,0 [51,6–74,7]	0,122
ICULOS	20,0 [13,0–24,5]	19,5 [8,5–42,0]	$< 10^{-3}$

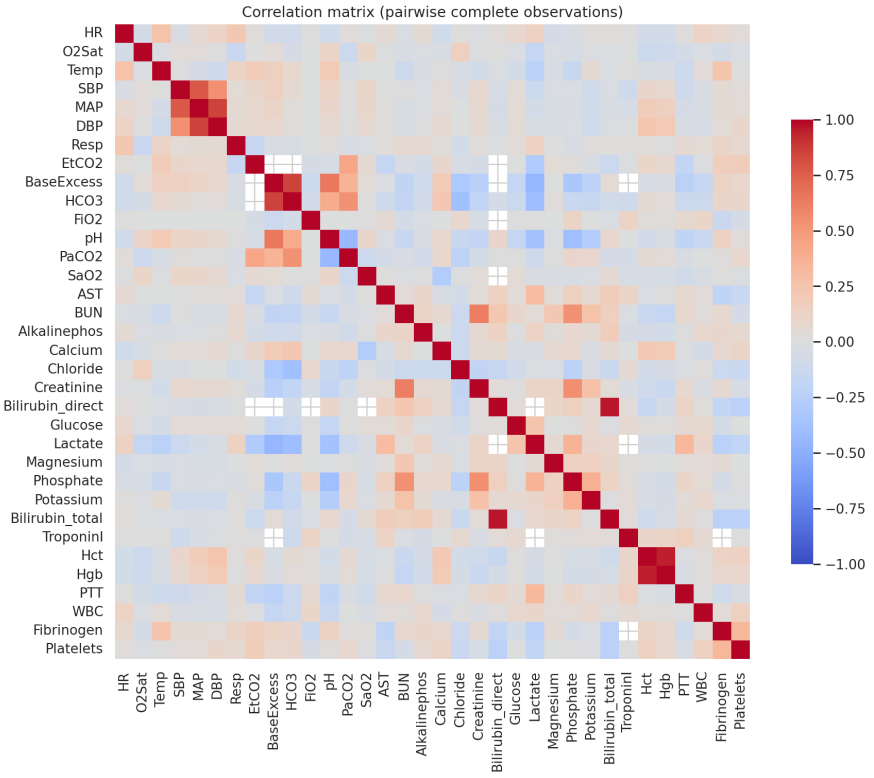


Figure 3.4: Matrice de corrélation entre variables temporelles (observations appariées).

3.3 Prétraitement

Le prétraitement respecte les règles suivantes, chacune visant à éviter une fuite d'information :

1. **Séparation par patient** (70 %/15 %/15 %), stratifiée sur la survenue du sepsis ; un même patient n'apparaît que dans un seul ensemble (tableau 3.3).

2. **Imputation causale** : report de la dernière valeur connue (*forward-fill*) à l'intérieur de chaque patient, sans jamais utiliser le futur.

3. **Masques d'observation** $m_{t,j} \in \{0, 1\}$ indiquant si la variable j a réellement été mesurée à l'heure t, et **temps écoulé depuis la dernière mesure** (compressé par $\log(1 + \cdot)$ et plafonné à 48 h), dans l'esprit de la modélisation des valeurs manquantes proposée pour les RNN [16].

4. **Normalisation** par $\tilde{x} = (x - \mu_{\text{train}})/(\sigma_{\text{train}} + \epsilon)$ avec les statistiques de l'ensemble d'entraînement uniquement, écrêtage à ± 5, puis remplissage des valeurs encore manquantes par 0.

5. **Fenêtres glissantes** : pour chaque heure t, l'entrée est $X_t \in \mathbb{R}^{T \times F}$ (les T dernières heures, complétées par des zéros en début de séjour) et la cible est $y_t = \texttt{SepsisLabel}(t)$.

6. **Déséquilibre** : pendant l'entraînement, toutes les lignes positives et un nouvel échantillon de négatifs (rapport 8:1) sont tirés à chaque époque, avec une pondération de la classe positive ; l'évaluation se fait toujours sur la *distribution naturelle*.

Le vecteur d'entrée comporte 108 variables : 34 valeurs temporelles et 6 statiques normalisées, 34 masques et 34 délais depuis la dernière mesure.

Table 3.3: Découpage des patients en entraînement, validation et test (stratifié sur la survenue du sepsis).

Ensemble	Patients	Patients septiques	Lignes (heures)	Lignes positives	% positives
Entraînement	28 235	2 052	1 086 436	19 560	1,80 %
Validation	6 050	440	231 472	4 162	1,80 %
Test	6 051	440	234 302	4 194	1,79 %

Chapitre 4

Méthodologie expérimentale

L'ensemble du code développé dans ce projet (notebook, figures et tableaux de résultats) est disponible dans le dépôt public du projet [24].

4.1 Architecture du LSTM et entraînement

Le modèle (PyTorch [15]) est un LSTM à L couches et H unités cachées, suivi d'une tête de classification appliquée au dernier état caché :

$$z = W_2\,\mathrm{ReLU}\big(W_1\,\mathrm{Dropout}(h_T) + b_1\big) + b_2, \qquad \hat{p} = \sigma(z), \tag{4.1}$$

avec une couche intermédiaire de $\max(H/2, 8)$ neurones. La perte est l'entropie croisée binaire pondérée

$$\mathcal{L} = -\frac{1}{N}\sum_{n=1}^{N}\Big[w_+\, y_n \log \hat{p}_n + (1-y_n)\log(1-\hat{p}_n)\Big], \qquad w_+ = \sqrt{r}, \tag{4.2}$$

où $r = 8$ est le rapport négatifs/positifs de l'échantillonnage d'entraînement. L'optimiseur est AdamW [14] avec écrêtage du gradient à 1,0, un bruit gaussien d'écart-type 0,1 sur les entrées comme régularisation, et des lots de 256 exemples. Une « époque » correspond à 50 % des exemples positifs, ce qui rend la validation deux fois plus fréquente.

4.2 Espace de recherche

L'espace est de dimension $D = 6$, mixte (entiers, réels, échelles logarithmiques) :

Table 4.1: Espace de recherche des hyperparamètres (tel qu'implémenté).

Hyperparamètre	Intervalle	Encodage	Remarque
`hidden` H	[16, 129[	entier (partie entière)	16 à 128 unités
`layers` L	[1, 4[	entier (partie entière)	1 à 3 couches
`dropout`	[0,2, 0,6]	réel	
$\log_{10}(lr)$	[−5, −2,5]	réel (échelle log)	$lr \in [10^{-5}, 3{,}16 \cdot 10^{-3}]$
$\log_{10}(wd)$	[−6, −2]	réel (échelle log)	$wd \in [10^{-6}, 10^{-2}]$
fenêtre T	[6, 33[	entier (partie entière)	6 à 32 heures

4.3 Les trois bras comparés

- **Manuelle (Default)** : $H = 64$, $L = 1$, dropout $= 0{,}2$, $lr = 10^{-3}$, $wd = 10^{-5}$, $T = 12$.
- **Recherche aléatoire (RS)** : 220 configurations tirées uniformément dans l'espace du tableau 4.1.
- **Évolution différentielle (DE)** : $NP = 20$, $G = 10$ générations, soit $NP(G + 1) = 220$ évaluations ; stratégie *current-to-best/1/bin*, $F = 0{,}6$, $CR = 0{,}9$, initialisation par hypercube latin [17], gestion des bornes par réflexion.

Les trois bras utilisent la même fonction objectif et les mêmes graines (nombres aléatoires communs), ce qui rend la comparaison appariée.

4.4 Fonction objectif et protocole de recherche

La fonction minimisée est $f(\mathbf{x}) = 1 - \overline{\text{AUPRC}}_{\text{val}}(\mathbf{x})$, où la moyenne porte sur *deux graines* d'entraînement, chaque entraînement étant limité à **10 époques** pour maîtriser le coût (approximation bon marché de la qualité finale). L'AUPRC est calculée sur un échantillon de 80 000 lignes de validation. Le meilleur individu de chaque méthode est ensuite ré-entraîné complètement.

4.5 Protocole d'évaluation finale

Chaque configuration retenue est ré-entraînée avec 3 graines (jusqu'à 60 époques, arrêt anticipé avec patience de 10). Pour chaque graine, les probabilités sont calibrées (Platt) sur la validation, et le seuil de décision τ maximisant le F_1 est choisi *sur la validation uniquement*. Les résultats sont rapportés sur le test : (i) moyenne $\pm$ écart-type sur les graines ; (ii) modèle d'*ensemble* moyennant les probabilités calibrées des 3 graines ; (iii) évaluation au niveau patient ; (iv) intervalles de confiance et différences appariées par bootstrap sur les patients ($B = 200$) [23].

Table 4.2: Paramètres de l'exécution (mode « fast » du notebook).

Paramètre	Valeur
Patients utilisés	40 336 (100 %)
Budget de recherche	220 évaluations par méthode (2 graines chacune)
Époques par évaluation (recherche)	10
Rapport négatifs/positifs à l'entraînement	8:1
Époques finales / patience	60 / 10
Graines finales	3
Réplicats bootstrap	200
Matériel	GPU CUDA
Fonctions de référence	5 répétitions, $D = 10$, $NP = 50$, $G = 300$

Chapitre 5

Validation de la DE sur des fonctions de référence

Avant de l'appliquer au LSTM, la DE est testée sans le bruit de l'entraînement, sur quatre fonctions classiques en dimension $D = 10$ dont l'optimum est décalé : Sphere (unimodale), Rosenbrock (vallée étroite), Rastrigin et Ackley (multimodales). Cinq variantes de DE sont comparées à une recherche aléatoire de même budget (environ 15 000 évaluations, 5 répétitions).

Table 5.1: Fonctions de référence ($D = 10$, $NP = 50$, $G = 300$, 5 répétitions) : valeur finale moyenne de f (rang entre parenthèses) et rang moyen.

Méthode	Sphere	Rosenbrock	Rastrigin	Ackley	Rang moy.
jDE (adaptive)	$7,4 \times 10^{-14}$ (1)	4,804 (4)	0,049 (1)	$3,0 \times 10^{-6}$ (1)	1,75
DE rand/1/bin	$3,9 \times 10^{-12}$ (2)	3,842 (2)	32,034 (4)	$1,2 \times 10^{-5}$ (2)	2,50
DE rand/2/bin	$2,9 \times 10^{-5}$ (3)	2,510 (1)	40,980 (5)	0,056 (3)	3,00
DE current-to-best/1	$2,4 \times 10^{-4}$ (4)	4,177 (3)	13,727 (2)	0,694 (4)	3,25
DE best/1/bin	$5,0 \times 10^{-3}$ (5)	5,096 (5)	14,408 (3)	3,174 (5)	4,50
Random Search	11,667 (6)	186,683 (6)	63,236 (6)	16,422 (6)	6,00

Le tableau 5.1 montre que la recherche aléatoire est la dernière sur les quatre fonctions, avec plusieurs ordres de grandeur d'écart (par exemple 11,7 contre $7,4 \times 10^{-14}$ sur Sphere pour jDE). La variante jDE obtient le meilleur rang moyen (1,75), suivie de rand/1/bin (2,50) ; *current-to-best/1*, la stratégie retenue plus loin pour le LSTM, se classe quatrième (3,25), bien que deuxième sur Rastrigin. Le détail figure en annexe (tableau B.1).

Sensibilité aux paramètres.. La figure 5.3 présente la sensibilité à F et CR (sur Rastrigin et Ackley, rand/1/bin, $NP = 40$, $G = 150$) et à NP (budget fixe de 8 000 évaluations). Les meilleurs réglages dépendent de la fonction : $F = 0,2$ avec CR faible à modéré est le plus performant sur ces deux fonctions, ce qui est cohérent avec leur caractère séparable, alors qu'un CR élevé est généralement préférable pour des problèmes dont les variables interagissent, comme c'est probablement le cas des hyperparamètres d'un réseau. Pour la taille de population, l'optimum se situe à $NP = 32$ pour Ackley, $NP = 16$ pour Rastrigin et $NP = 32$ à 64 pour Rosenbrock, ce qui encadre le choix $NP = 20$.

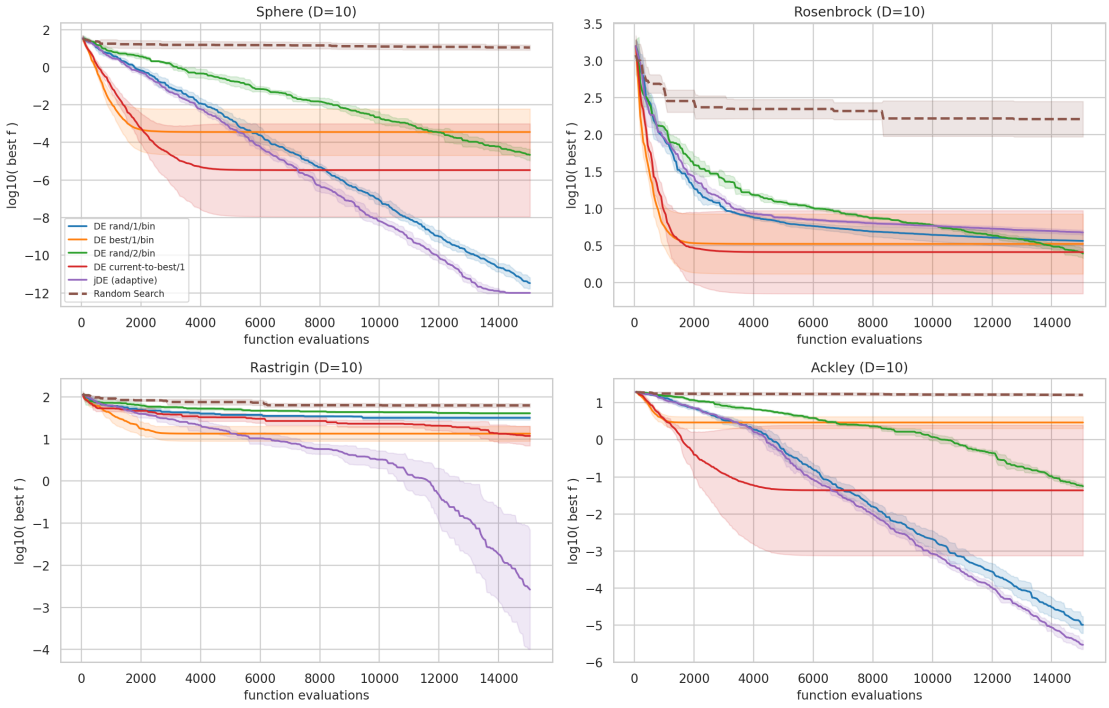


Figure 5.1: Courbes de convergence des variantes de DE et de la recherche aléatoire sur les fonctions de référence.

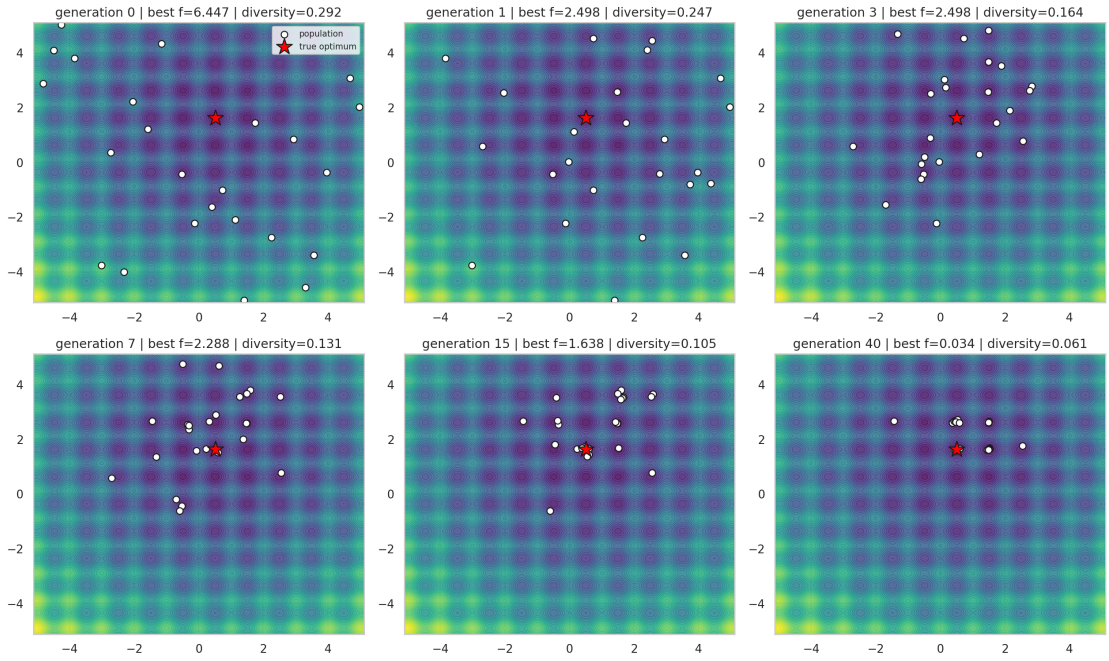


Figure 5.2: Évolution de la population de DE sur une fonction de Rastrigin en dimension 2 (NP = 24).

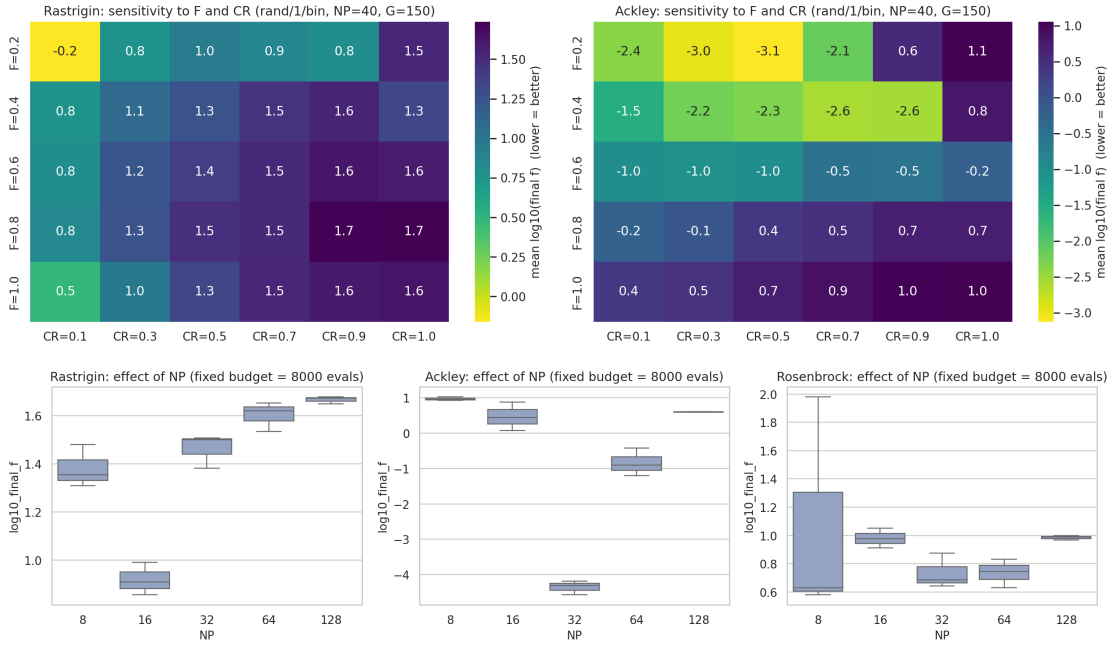


Figure 5.3: Sensibilité de la DE : (haut) aux paramètres F et CR ; (bas) à la taille de population NP à budget fixe.

Chapitre 6

Résultats

6.1 Hyperparamètres trouvés

Le tableau 6.1 donne la meilleure configuration de chaque méthode (voir aussi l'annexe D).

Table 6.1: Meilleurs hyperparamètres obtenus par chaque méthode.

Méthode	hidden	couches	dropout	lr	wd	fenêtre T	paramètres	AUPRC val.	temps/éval. (s)
Manuelle (Default)	64	1	0,200	$1,0 \times 10^{-3}$	$1,0 \times 10^{-5}$	12	46 657	0,0905	4,3
Recherche aléatoire	63	2	0,481	$5,7 \times 10^{-4}$	$1,7 \times 10^{-4}$	6	77 868	0,0908	10,8
Évolution différentielle	98	2	0,255	$2,9 \times 10^{-3}$	$7,7 \times 10^{-6}$	29	164 053	0,0952	23,9

La DE retient un réseau plus large (98 unités, 2 couches), un taux d'apprentissage élevé ($2{,}95 \times 10^{-3}$), une très faible décroissance des poids et une fenêtre longue (29 h). Ce modèle compte 164 053 paramètres, soit 3,5 fois plus que la configuration manuelle et 2,1 fois plus que celle de la recherche aléatoire, et son temps d'entraînement par évaluation est de 23,9 s contre 4,3 s et 10,8 s. La DE a ainsi coûté 68,6 minutes contre 49,4 minutes pour la recherche aléatoire (+39 %), à nombre d'évaluations identique.

Remarque sur les bornes.. Le taux d'apprentissage trouvé ($\log_{10}(lr) = -2{,}53$) est quasiment sur la borne supérieure de l'espace ($-2{,}5$), et la fenêtre (29 h) est proche de la borne 32 h. L'optimum se situe donc au bord de l'espace de recherche, ce qui suggère qu'il pourrait être élargi.

6.2 Dynamique de la recherche

La figure 6.1 et le tableau 6.2 montrent que la DE dépasse la configuration manuelle (AUPRC de validation de 0,0905) dès la 49e évaluation (0,0945 à ce stade), puis atteint son maximum de 0,0952 vers la 109e. La recherche aléatoire, elle, dépasse la configuration manuelle à la 52e évaluation mais plafonne à 0,0908 (+0,0003). À budget complet, la DE conserve donc un écart de +0,0044 sur la recherche aléatoire, soit +5,2 % d'AUPRC relatif à la configuration manuelle.

Le tableau 6.3 montre que l'avantage de la DE ne se limite pas au meilleur point : l'AUPRC moyenne des essais est plus élevée (0,0865 contre 0,0781), leur dispersion plus faible, 15,9 % des essais (35 sur 220) dépassent la configuration manuelle contre

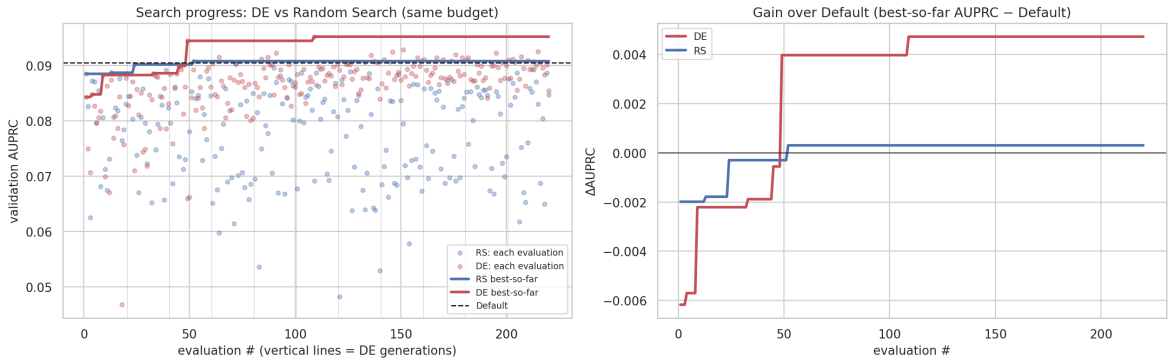


Figure 6.1: Progression de la recherche : chaque point est une évaluation, les courbes donnent la meilleure valeur obtenue ; à droite, gain par rapport à la configuration manuelle.

Table 6.2: Meilleure AUPRC de validation atteinte en fonction du budget consommé.

Évaluations	DE	Recherche aléatoire	DE − RS
55	0,0945	0,0908	0,0037
110	0,0952	0,0908	0,0044
165	0,0952	0,0908	0,0044
220	0,0952	0,0908	0,0044

Table 6.3: Statistiques de qualité des 220 essais de chaque méthode (AUPRC de validation, protocole de recherche).

Indicateur	DE	Recherche aléatoire
Meilleure AUPRC	0,0952	0,0908
AUPRC moyenne	0,0865	0,0781
AUPRC médiane	0,0877	0,0806
Écart-type	0,0054	0,0086
% d'essais > Default	15,9	0,5
% d'essais dans le top-10 % global	18,6	1,4
Évaluations pour dépasser Default	49	52

un seul essai (0,5 %) pour la recherche aléatoire, et 18,6 % des essais de la DE figurent dans le dixième supérieur des essais cumulés contre 1,4 %. La DE concentre donc ses échantillons dans la région performante.

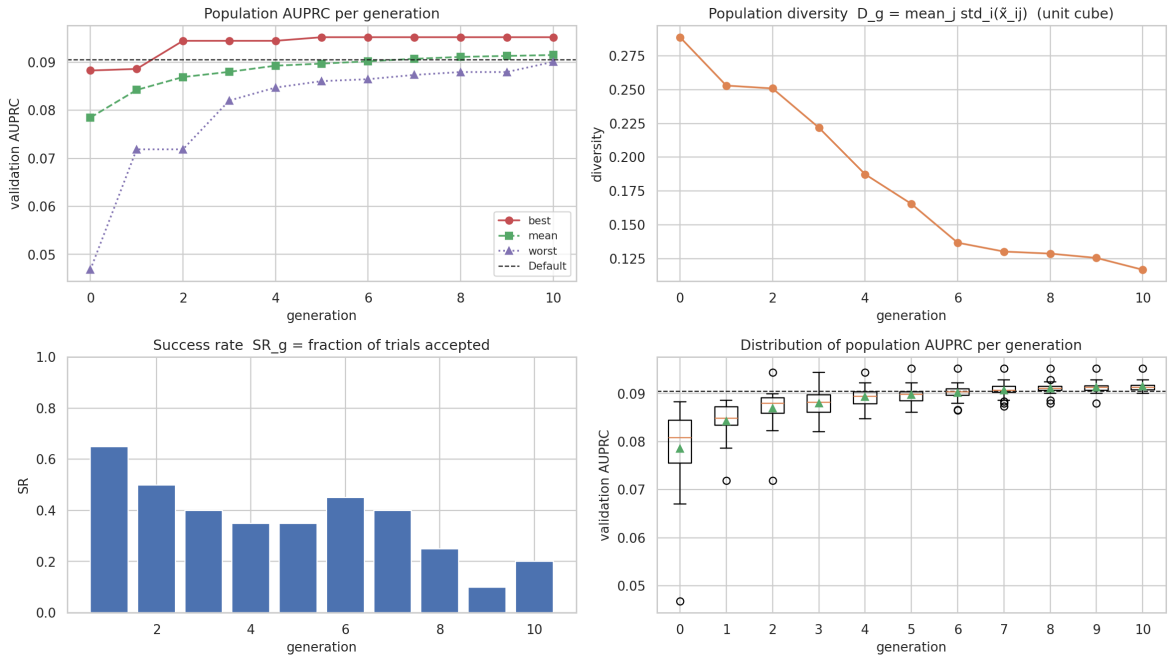


Figure 6.2: Diagnostics de la DE : AUPRC de la population, diversité, taux de succès des essais et distribution par génération.

Table 6.4: Historique de la population de DE par génération (AUPRC de validation $= 1 - f$).

Gén.	Évaluations	Meilleure	Moyenne	Pire	Diversité	Succès
0	20	0,0883	0,0785	0,0468	0,289	–
1	40	0,0886	0,0842	0,0719	0,253	65 %
2	60	0,0945	0,0869	0,0719	0,251	50 %
3	80	0,0945	0,0880	0,0820	0,222	40 %
4	100	0,0945	0,0893	0,0847	0,187	35 %
5	120	0,0952	0,0897	0,0861	0,166	35 %
6	140	0,0952	0,0902	0,0865	0,137	45 %
7	160	0,0952	0,0907	0,0874	0,130	40 %
8	180	0,0952	0,0911	0,0880	0,129	25 %
9	200	0,0952	0,0913	0,0880	0,126	10 %
10	220	0,0952	0,0915	0,0901	0,117	20 %

Comme le montrent la figure 6.2 et le tableau 6.4, la population passe d'une AUPRC moyenne de 0,0785 (génération 0) à 0,0915 (génération 10), alors que la diversité décroît de 0,289 à 0,117 et que le taux de succès des essais diminue de 65 % à 20 %. Le meilleur individu est stable à partir de la génération 5 : la phase d'exploitation domine la fin

de la recherche, et le budget de 10 générations est court devant les recommandations usuelles ($NP \approx 5D$ à $10D$, soit 30 à 60 individus ici, avec davantage de générations).

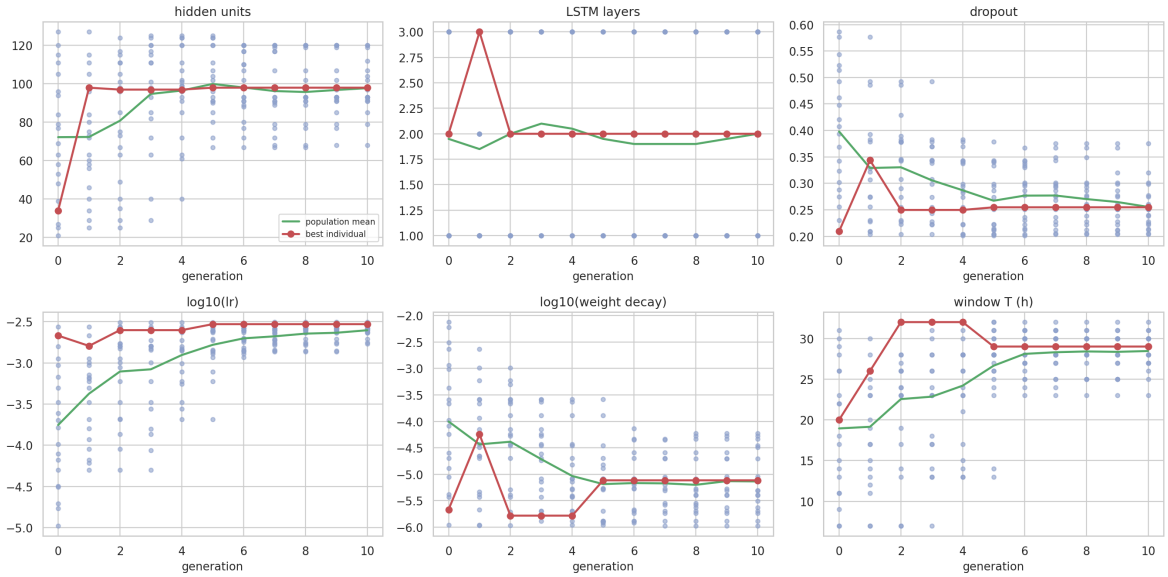


Figure 6.3: Trajectoires des hyperparamètres au cours des générations de la DE.

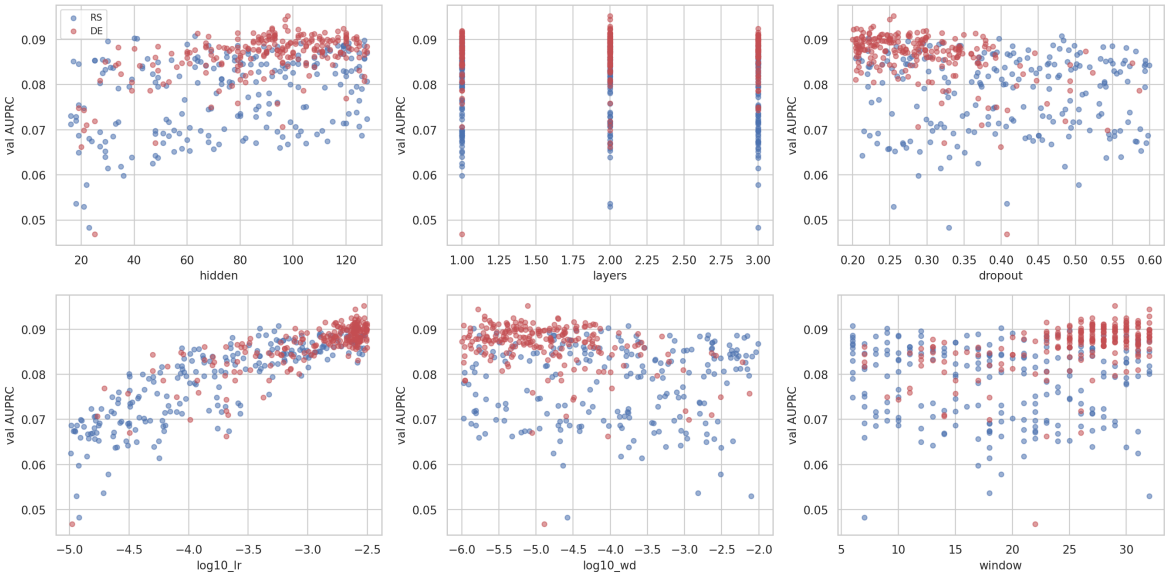


Figure 6.4: Relation entre chaque hyperparamètre et l'AUPRC de validation pour les essais de la DE et de la recherche aléatoire.

6.3 Importance des hyperparamètres

Le taux d'apprentissage domine nettement ($\rho = +0{,}85$ sur l'ensemble des essais), suivi du dropout ($-0{,}44$, des valeurs faibles étant favorables), de la fenêtre ($+0{,}40$) et de la taille cachée ($+0{,}40$). Le nombre de couches n'a pas d'effet monotone détectable. Ce résultat doit être interprété avec prudence : comme chaque essai est limité à 10 époques,

Table 6.5: Corrélation de Spearman entre chaque hyperparamètre et l'AUPRC de validation.

Hyperparamètre	ρ (global)	p	ρ (DE)	ρ (RS)
$\log_{10}(lr)$	0,85	$< 10^{-9}$	0,68	0,85
dropout	-0,44	$< 10^{-9}$	-0,41	-0,03
fenêtre T	0,40	$< 10^{-9}$	0,48	-0,11
hidden	0,40	$< 10^{-9}$	0,39	0,33
$\log_{10}(wd)$	-0,32	$< 10^{-9}$	-0,25	0,07
couches	-0,00	1,000	0,02	-0,13

un lr élevé accélère la convergence et est donc favorisé par l'objectif, indépendamment de la qualité à convergence (voir la section 6.4.3).

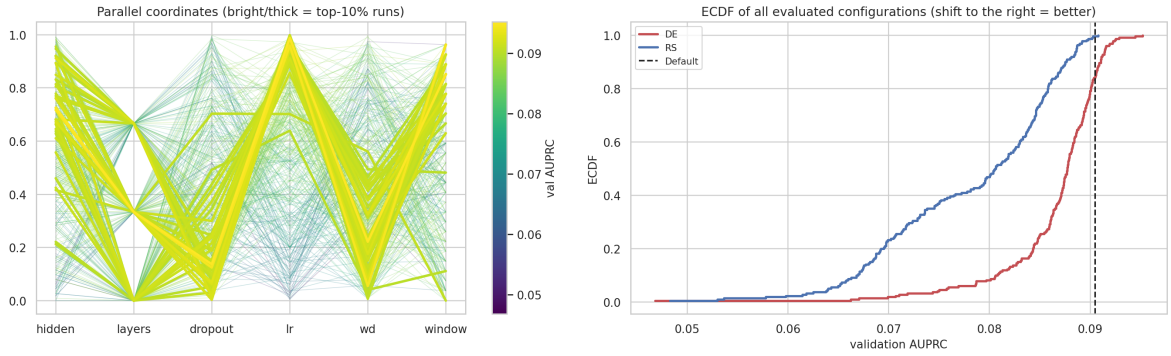


Figure 6.5: Coordonnées parallèles des meilleurs essais et fonction de répartition empirique (ECDF) de l'AUPRC de validation.

6.4 Évaluation finale sur le jeu de test

6.4.1 Résultats moyens sur trois graines

Table 6.6: Résultats sur le jeu de test : métriques de classement (moyenne ± écart-type sur 3 graines).

Méthode	AUPRC	AUROC	Brier
Manuelle (Default)	0,1248 ± 0,0041	0,8420 ± 0,0025	0,0166 ± 0,0000
Recherche aléatoire	0,1203 ± 0,0040	0,8393 ± 0,0098	0,0166 ± 0,0000
Évolution différentielle	0,1222 ± 0,0057	0,8399 ± 0,0038	0,0166 ± 0,0000

Les trois méthodes sont très proches (tableaux 6.6 et 6.7). L'AUPRC moyenne est de 0,1248 pour la configuration manuelle, 0,1203 pour la recherche aléatoire et 0,1222 pour la DE, avec des écarts-types de 0,004 à 0,006 : les différences entre méthodes sont du même ordre que la variabilité entre graines. L'AUROC est de 0,84 pour les trois. Pour référence, un classifieur aléatoire aurait une AUPRC d'environ 0,018 ; les modèles

Table 6.7: Résultats sur le jeu de test : métriques au seuil choisi sur la validation (moyenne ± écart-type sur 3 graines).

Méthode	F1	Précision	Rappel	Spécificité	MCC	Exactitude
Manuelle (Default)	0,2036 ± 0,0079	0,1537 ± 0,0118	0,3034 ± 0,0130	0,9693 ± 0,0040	0,1957 ± 0,0058	0,9574 ± 0,0037
Recherche aléatoire	0,1861 ± 0,0098	0,1342 ± 0,0292	0,3438 ± 0,0976	0,9564 ± 0,0206	0,1875 ± 0,0051	0,9454 ± 0,0185
Évolution différentielle	0,1893 ± 0,0075	0,1344 ± 0,0131	0,3283 ± 0,0471	0,9608 ± 0,0104	0,1869 ± 0,0052	0,9494 ± 0,0094

sont donc environ sept fois meilleurs que le hasard. Les exactitudes (0,945 à 0,957) sont élevées mais peu informatives compte tenu du déséquilibre.

6.4.2 Modèle d'ensemble

Table 6.8: Résultats sur le jeu de test du modèle d'ensemble (moyenne des probabilités calibrées des 3 graines).

Méthode	AUPRC	AUROC	F1	Précision	Rappel	Spécif.	MCC	Brier
Manuelle (Default)	0,1343	0,8499	0,2017	0,1890	0,2163	0,9831	0,1866	0,0166
Recherche aléatoire	0,1277	0,8485	0,2035	0,1785	0,2365	0,9802	0,1888	0,0166
Évolution différentielle	0,1341	0,8496	0,2056	0,1489	0,3319	0,9654	0,2014	0,0166

L'ensemble des trois graines améliore sensiblement les trois méthodes (AUPRC de 0,134 pour Default et DE, 0,128 pour RS), mais ne les sépare pas : l'AUPRC de la DE (0,1341) est pratiquement égale à celle de la configuration manuelle (0,1343). Le rappel de la DE est plus élevé (0,332 contre 0,216) au prix d'une précision plus faible (0,149 contre 0,189) : c'est l'effet du seuil choisi sur la validation (maximisation du F_1), non d'un meilleur classement, puisque le F_1 (0,206 contre 0,202) et le MCC (0,201 contre 0,187) évoluent peu.

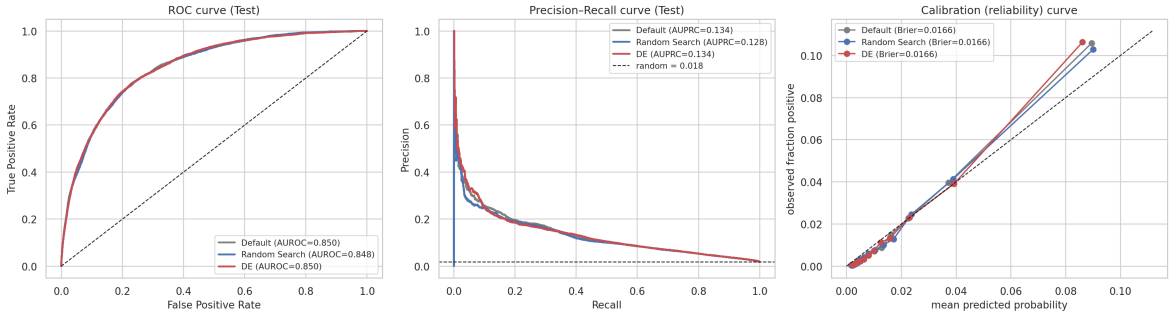


Figure 6.6: Courbes ROC et précision–rappel sur le test, et courbe de calibration des trois modèles.

Les courbes de la figure 6.6 sont quasiment superposées. Le score de Brier est identique (0,0166) pour les trois modèles, et les courbes de calibration montrent des probabilités globalement bien calibrées grâce à la calibration de Platt, avec une légère sous-estimation du risque dans les probabilités élevées.

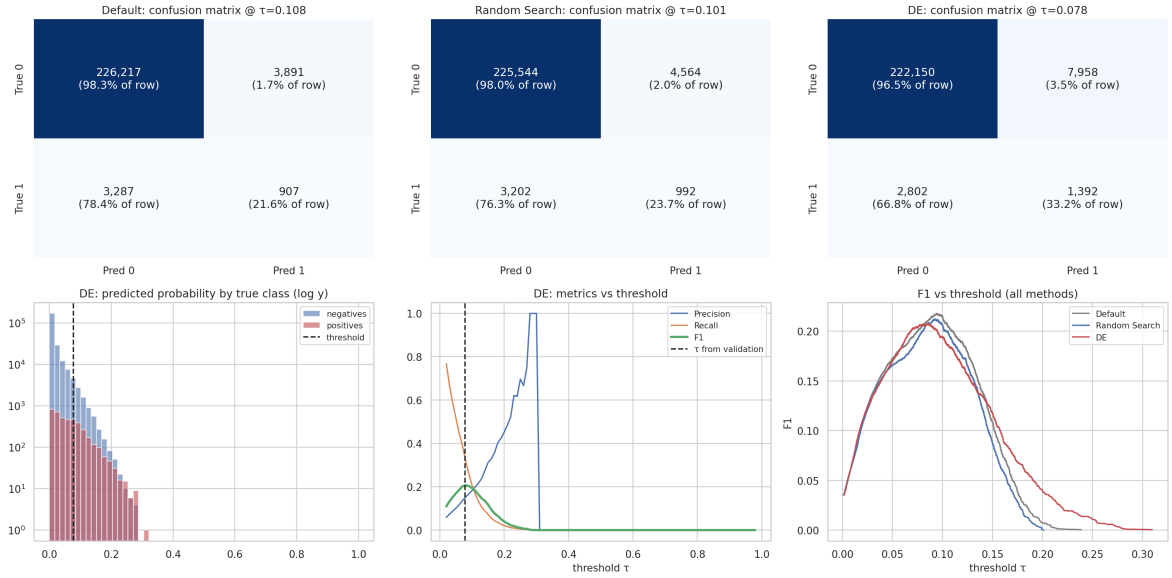


Figure 6.7: Matrices de confusion, distribution des scores par classe et sensibilité des métriques au seuil de décision.

6.4.3 Surapprentissage et variabilité entre graines

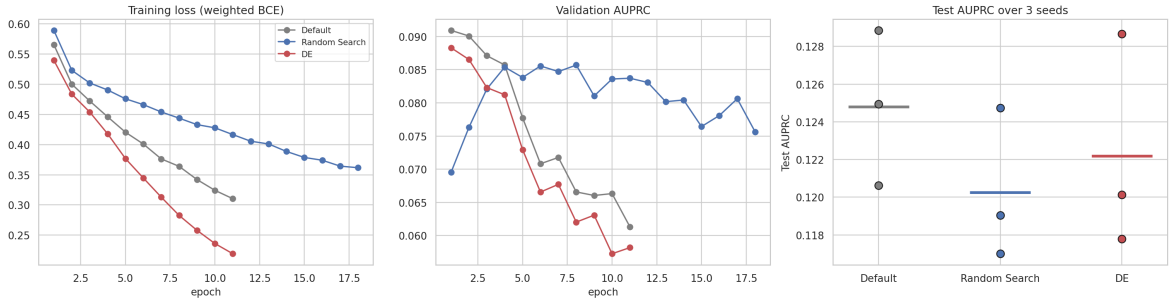


Figure 6.8: Courbes d'apprentissage (perte d'entraînement et AUPRC de validation) et AUPRC de test par graine.

La figure 6.8 révèle un point important : pour la configuration manuelle et pour celle de la DE, l'AUPRC de validation est maximale dès les toutes premières époques puis se dégrade, alors que la perte d'entraînement continue de décroître, ce qui traduit un surapprentissage rapide (la recherche aléatoire, avec un lr plus faible et un dropout plus fort, apprend plus lentement). La DE, dont l'objectif est estimé après seulement 10 époques, tend ainsi à sélectionner des modèles à forte capacité qui atteignent leur pic très tôt. Le tableau C.1 en annexe détaille les résultats par graine.

6.5 Évaluation au niveau du patient

Au niveau clinique, la question pertinente est de savoir si le patient septique a déclenché une alarme, et avec quelle avance. L'avance est définie par rapport à l'instant clinique

du sepsis (début de l'étiquette +6 h) ; une valeur négative signifie une alarme tardive.

Table 6.9: Évaluation au niveau du patient (440 patients septiques du jeu de test).

Méthode	Sensibilité patient	Alarme avant l'étiquette	Avance méd. (h)	Avance moy. (h)	Patients non sept. alarmés	Alarmes / 100 h
Manuelle (Default)	35,5 %	25,0 %	23,5	45,6	0,91 %	0,25
Recherche aléatoire	38,6 %	26,8 %	27,5	46,0	1,53 %	0,38
Évolution différentielle	53,0 %	36,1 %	24,0	45,2	5,69 %	1,28

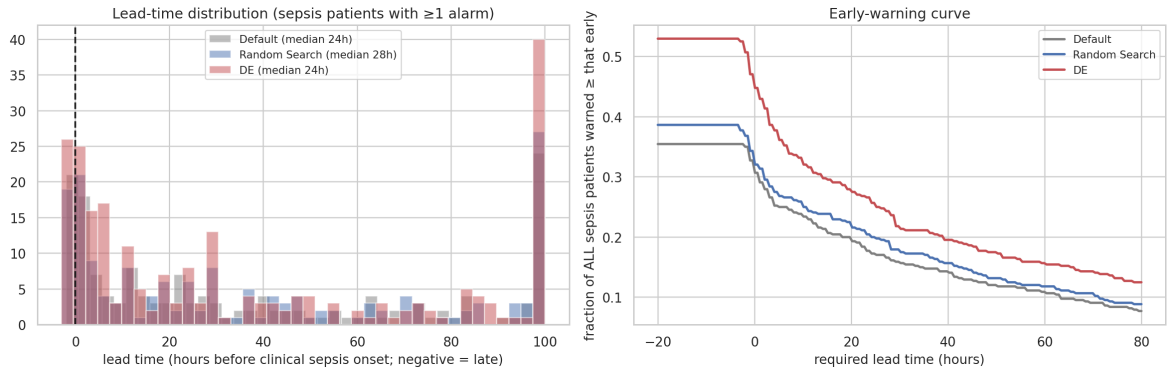


Figure 6.9: Distribution des délais d'alerte (valeurs tronquées à $[-30, 100]$ heures) et courbe d'alerte précoce.

Avec le seuil choisi sur la validation, la DE détecte 53,0 % des patients septiques, contre 35,5 % pour la configuration manuelle et 38,6 % pour la recherche aléatoire, et 36,1 % des patients reçoivent une alarme avant ou dès le début de l'étiquette (contre 25,0 % et 26,8 %). L'avance médiane est comparable (24,0 ; 23,5 et 27,5 heures). Cependant, la DE génère aussi davantage de fausses alarmes : 5,69 % des patients non septiques déclenchent au moins une alarme (contre 0,91 % et 1,53 %), soit 1,28 alarme pour 100 heures-patient (contre 0,25 et 0,38). Compte tenu de l'égalité des AUPRC et AUROC, ce gain de sensibilité s'interprète comme un déplacement le long de la même courbe précision–rappel (un seuil plus permissif), et non comme un modèle plus discriminant. De plus, l'avance moyenne (≈ 45 h) est tirée vers le haut par des alarmes très précoces, qui ne sont pas nécessairement pertinentes cliniquement.

6.6 Significativité statistique

Les intervalles de confiance à 95 % des trois méthodes se recouvrent largement (tableau 6.10). Les différences appariées (tableau 6.11) sont minuscules et leurs intervalles contiennent zéro : $\Delta\text{AUPRC} = -0{,}0001$ $[-0{,}0135 ; +0{,}0123]$ pour DE − Default, et $+0{,}0065$ $[-0{,}0061 ; +0{,}0175]$ pour DE − RS. La probabilité bootstrap que la DE ne dépasse pas la recherche aléatoire est de 0,15, ce qui est insuffisant pour conclure. Au niveau du test, aucun avantage de la DE n'est donc démontré.

Table 6.10: Intervalles de confiance à 95 % par bootstrap au niveau patient ($B = 200$) sur le test (modèle d'ensemble).

Méthode	Métrique	Moyenne	IC 95 %
Manuelle (Default)	AUPRC	0,1365	[0,1151 ; 0,1562]
Manuelle (Default)	AUROC	0,8503	[0,8348 ; 0,8643]
Recherche aléatoire	AUPRC	0,1299	[0,1097 ; 0,1516]
Recherche aléatoire	AUROC	0,8490	[0,8344 ; 0,8634]
Évolution différentielle	AUPRC	0,1365	[0,1125 ; 0,1577]
Évolution différentielle	AUROC	0,8498	[0,8356 ; 0,8632]

Table 6.11: Différences appariées par bootstrap (Δ) entre DE et les deux autres méthodes.

Comparaison	Métrique	Δ moyen	IC 95 %	$P(\Delta \leq 0)$
DE − Default	AUPRC	-0,0001	[-0,0135 ; 0,0123]	0,500
DE − Default	AUROC	-0,0006	[-0,0061 ; 0,0045]	0,565
DE − RS	AUPRC	0,0065	[-0,0061 ; 0,0175]	0,150
DE − RS	AUROC	0,0007	[-0,0057 ; 0,0074]	0,430

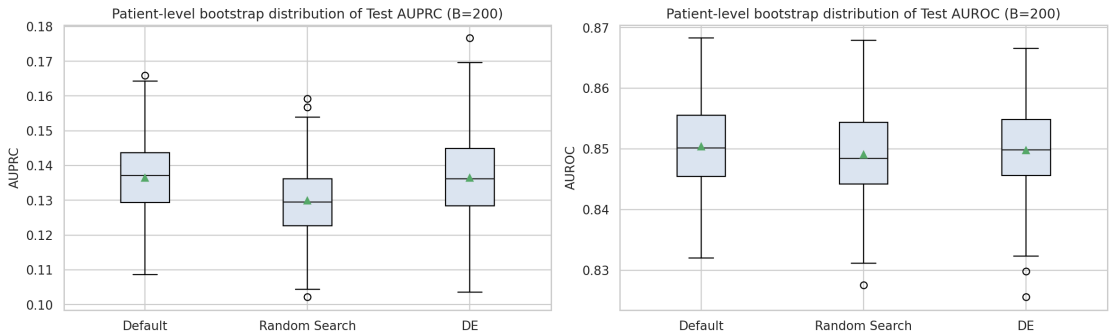


Figure 6.10: Distributions bootstrap des AUPRC et AUROC et des différences appariées.

Chapitre 7

Discussion

7.1 Ce que montrent les résultats

Trois constats se dégagent. **(1) L'algorithme fonctionne** : sur les fonctions de référence, la DE écrase la recherche aléatoire, et lors de la recherche d'hyperparamètres elle trouve une configuration meilleure en validation (+5,2 % d'AUPRC relative) et concentre ses essais dans la région performante, ce qui est son comportement attendu. **(2) Cet avantage ne se transfère pas au test** : les AUPRC et AUROC finales sont statistiquement indistinguables, la différence en validation (0,0044) restant inférieure à la dispersion entre graines (0,004 à 0,006) et au bruit d'échantillonnage du test. **(3) Les gains en sensibilité patient** de la DE relèvent du seuil de décision, avec un coût en fausses alarmes.

7.2 Explications possibles

- **Objectif proxy.** Un entraînement de 10 époques favorise les modèles qui apprennent vite (taux d'apprentissage élevé, grande capacité), non ceux qui généralisent le mieux à convergence ; l'optimum trouvé est d'ailleurs au bord de l'espace pour lr.
- **Sélection sur un sous-ensemble bruité.** La validation de la recherche repose sur 80 000 lignes et 2 graines : les écarts de 0,004 sont proches du bruit (effet de « malédiction du vainqueur »). Les AUPRC de validation (autour de 0,09) et de test (autour de 0,12–0,13) ne sont d'ailleurs pas directement comparables, les protocoles d'entraînement et d'évaluation étant différents.
- **Budget réduit.** Avec $NP = 20$ et $G = 10$ pour un espace de dimension 6, la DE est loin de son régime favorable ; la convergence prématurée (diversité 0,117, succès 20 % en fin de recherche) est possible.
- **Choix de la stratégie.** Les benchmarks classent jDE et rand/1/bin devant current-to-best/1, retenue ici ; une stratégie plus exploratrice pourrait être préférable.
- **Plafond du modèle.** Le LSTM sur ces données semble limité par l'information disponible (données lacunaires, signal faible avant l'apparition) plus que par

ses hyperparamètres : la configuration manuelle est déjà proche de l'optimum observable.

7.3 Limites de l'étude

- Une seule exécution de chaque méthode de recherche : la variabilité de la recherche elle-même n'est pas estimée.
- Trois graines et 200 réplicats bootstrap seulement (mode « fast »).
- Absence de validation externe : les hôpitaux A et B sont mélangés, alors qu'un décalage de distribution entre hôpitaux est documenté pour ces données [1]. Un entraînement sur A et un test sur B serait plus exigeant.
- La métrique officielle du défi (score d'utilité) n'est pas optimisée ni rapportée.
- Aucune comparaison avec des modèles concurrents (arbres de gradient, GRU, Transformers) ni avec l'optimisation bayésienne.
- Il ne s'agit pas d'un dispositif médical et aucune évaluation prospective n'a été menée.

7.4 Perspectives

1. Augmenter le budget ($NP = 30$ à 60, davantage de générations) et élargir les bornes de lr et de la fenêtre.
2. Utiliser un objectif plus fidèle : plus d'époques avec arrêt anticipé, davantage de graines, ou une validation plus grande.
3. Tester jDE ou rand/1/bin à la place de current-to-best/1.
4. Optimiser directement le score d'utilité PhysioNet, ou adopter une DE multi-objectif (AUPRC, délai d'alerte, taille du modèle).
5. Comparer à l'optimisation bayésienne (TPE, Optuna [13]) à budget égal.
6. Élargir l'espace aux architectures (GRU, attention) et au rapport d'échantillonnage des négatifs.

Conclusion générale

Ce travail a comparé, à budget égal de 220 entraînements, trois façons de régler un LSTM de prédiction précoce du sepsis : une configuration manuelle, une recherche aléatoire et une Évolution Différentielle implémentée de zéro. L'algorithme a été validé sur quatre fonctions de référence, où il surpasse largement la recherche aléatoire (rang moyen de 1,75 pour jDE contre 6 pour la recherche aléatoire). Sur le problème clinique, la DE obtient la meilleure AUPRC de validation (0,0952 contre 0,0908 et 0,0905) et échantillonne beaucoup plus souvent des configurations performantes, mais l'évaluation sur le test, appuyée par plusieurs graines et un bootstrap au niveau patient, ne démontre pas de supériorité (AUPRC d'ensemble $\approx$ 0,134, AUROC $\approx$ 0,85 pour les trois méthodes). Les différences observées au niveau patient (sensibilité de 53,0 % contre 35,5 %) proviennent d'un seuil plus permissif, avec davantage de fausses alarmes.

En résumé, la DE est un optimiseur efficace et fiable en tant qu'algorithme, mais, dans ce régime de budget réduit et avec un objectif estimé par un entraînement court, elle n'apporte pas de gain démontrable de généralisation pour ce problème. Les pistes proposées (budget, objectif plus fidèle, validation externe, métrique d'utilité) permettraient de tester si ce résultat persiste dans un cadre plus exigeant.

Bibliographie

[1] M. A. Reyna, C. S. Josef, R. Jeter, S. P. Shashikumar, M. B. Westover, S. Nemati, G. D. Clifford et A. Sharma, « Early Prediction of Sepsis From Clinical Data: The PhysioNet/Computing in Cardiology Challenge 2019 », *Critical Care Medicine*, vol. 48, no 2, pp. 210–217, 2020.

[2] M. A. Reyna *et al.*, « Early Prediction of Sepsis from Clinical Data: The PhysioNet/Computing in Cardiology Challenge 2019 (version 1.0.0) », PhysioNet, 2019. `https://physionet.org/content/challenge-2019/1.0.0/`

[3] A. L. Goldberger *et al.*, « PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals », *Circulation*, vol. 101, no 23, pp. e215–e220, 2000.

[4] M. Singer *et al.*, « The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3) », *JAMA*, vol. 315, no 8, pp. 801–810, 2016.

[5] K. E. Rudd *et al.*, « Global, regional, and national sepsis incidence and mortality, 1990–2017: analysis for the Global Burden of Disease Study », *The Lancet*, vol. 395, no 10219, pp. 200–211, 2020. doi:10.1016/S0140-6736(19)32989-7.

[6] C. W. Seymour *et al.*, « Time to Treatment and Mortality during Mandated Emergency Care for Sepsis », *New England Journal of Medicine*, vol. 376, no 23, pp. 2235–2244, 2017. doi:10.1056/NEJMoa1703058.

[7] S. Hochreiter et J. Schmidhuber, « Long Short-Term Memory », *Neural Computation*, vol. 9, no 8, pp. 1735–1780, 1997.

[8] R. Storn et K. Price, « Differential Evolution – A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces », *Journal of Global Optimization*, vol. 11, no 4, pp. 341–359, 1997.

[9] J. Brest, S. Greiner, B. Boskovic, M. Mernik et V. Zumer, « Self-Adapting Control Parameters in Differential Evolution: A Comparative Study on Numerical Benchmark Problems », *IEEE Transactions on Evolutionary Computation*, vol. 10, no 6, pp. 646–657, 2006.

[10] S. Das et P. N. Suganthan, « Differential Evolution: A Survey of the State-of-the-Art », *IEEE Transactions on Evolutionary Computation*, vol. 15, no 1, pp. 4–31, 2011.

[11] J. Bergstra et Y. Bengio, « Random Search for Hyper-Parameter Optimization », *Journal of Machine Learning Research*, vol. 13, pp. 281–305, 2012.

[12] J. Bergstra, R. Bardenet, Y. Bengio et B. Kégl, « Algorithms for Hyper-Parameter Optimization », *Advances in Neural Information Processing Systems 24 (NIPS)*, 2011.

[13] T. Akiba, S. Sano, T. Yanase, T. Ohta et M. Koyama, « Optuna: A Next-generation Hyperparameter Optimization Framework », *Proc. ACM SIGKDD (KDD)*, pp. 2623–2631, 2019.

[14] I. Loshchilov et F. Hutter, « Decoupled Weight Decay Regularization », *International Conference on Learning Representations (ICLR)*, 2019.

[15] A. Paszke *et al.*, « PyTorch: An Imperative Style, High-Performance Deep Learning Library », *Advances in Neural Information Processing Systems 32 (NeurIPS)*, pp. 8024–8035, 2019.

[16] Z. Che, S. Purushotham, K. Cho, D. Sontag et Y. Liu, « Recurrent Neural Networks for Multivariate Time Series with Missing Values », *Scientific Reports*, vol. 8, art. 6085, 2018.

[17] M. D. McKay, R. J. Beckman et W. J. Conover, « A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output from a Computer Code », *Technometrics*, vol. 21, no 2, pp. 239–245, 1979.

[18] J. Davis et M. Goadrich, « The Relationship Between Precision-Recall and ROC Curves », *Proc. International Conference on Machine Learning (ICML)*, pp. 233–240, 2006.

[19] T. Saito et M. Rehmsmeier, « The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets », *PLOS ONE*, vol. 10, no 3, e0118432, 2015.

[20] D. Chicco et G. Jurman, « The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation », *BMC Genomics*, vol. 21, art. 6, 2020.

[21] G. W. Brier, « Verification of Forecasts Expressed in Terms of Probability », *Monthly Weather Review*, vol. 78, no 1, pp. 1–3, 1950.

[22] J. C. Platt, « Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods », in *Advances in Large Margin Classifiers*, MIT Press, pp. 61–74, 1999.

[23] B. Efron et R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall, 1993.

[24] S. Gasmi, I. El Ghidouni et C. Al-aissaoui, « Prédiction précoce du sepsis : LSTM + Évolution Différentielle (DE) – code source du projet », dépôt GitHub, 2026. `https://github.com/SohayebGasmi-IA79/DE-LSTM-PROJET-EARLY-SEPSIS` (consulté le 24 octobre 2026).

Annexe A

Valeurs manquantes par variable

Table A.1: Taux de valeurs manquantes par variable (ensemble des 40 336 patients).

Variable	Manquant (%)	Type
Bilirubin_direct	99,81	laboratoire
Fibrinogen	99,34	laboratoire
TroponinI	99,05	laboratoire
Bilirubin_total	98,51	laboratoire
Alkalinephos	98,39	laboratoire
AST	98,38	laboratoire
Lactate	97,33	laboratoire
PTT	97,06	laboratoire
SaO2	96,55	laboratoire
EtCO2	96,29	signe vital
Phosphate	95,99	laboratoire
HCO3	95,81	laboratoire
Chloride	95,46	laboratoire
BaseExcess	94,58	laboratoire
PaCO2	94,44	laboratoire
Calcium	94,12	laboratoire
Platelets	94,06	laboratoire
Creatinine	93,90	laboratoire
Magnesium	93,69	laboratoire
WBC	93,59	laboratoire
BUN	93,13	laboratoire
pH	93,07	laboratoire
Hgb	92,62	laboratoire
FiO2	91,67	laboratoire
Hct	91,15	laboratoire

Variable	Manquant (%)	Type
Potassium	90,69	laboratoire
Glucose	82,89	laboratoire
Temp	66,16	signe vital
Unit2	39,43	statique
Unit1	39,43	statique
DBP	31,35	signe vital
Resp	15,35	signe vital
SBP	14,58	signe vital
O2Sat	13,06	signe vital
MAP	12,45	signe vital
HR	9,88	signe vital
HospAdmTime	0,00	statique
Age	0,00	statique
Gender	0,00	statique
ICULOS	0,00	statique

Annexe B

Résultats détaillés des fonctions de référence

Table B.1: Résultats détaillés sur les fonctions de référence (valeur finale de f sur 5 répétitions).

Fonction	Méthode	Moyenne	Écart-type	Médiane	Meilleur
Sphere	jDE (adaptive)	$7,4 \times 10^{-14}$	$6,4 \times 10^{-14}$	$3,1 \times 10^{-14}$	$2,2 \times 10^{-14}$
Sphere	DE rand/1/bin	$3,9 \times 10^{-12}$	$2,7 \times 10^{-12}$	$3,7 \times 10^{-12}$	$6,0 \times 10^{-13}$
Sphere	DE rand/2/bin	$2,9 \times 10^{-5}$	$2,7 \times 10^{-5}$	$1,7 \times 10^{-5}$	$1,1 \times 10^{-5}$
Sphere	DE current-to-best/1	$2,4 \times 10^{-4}$	$3,2 \times 10^{-4}$	$6,1 \times 10^{-5}$	$3,1 \times 10^{-10}$
Sphere	DE best/1/bin	$5,0 \times 10^{-3}$	$8,9 \times 10^{-3}$	$2,0 \times 10^{-4}$	$1,0 \times 10^{-5}$
Sphere	Random Search	11,667	3,768	11,813	6,544
Rosenbrock	DE rand/2/bin	2,510	0,411	2,470	2,090
Rosenbrock	DE rand/1/bin	3,842	1,282	2,938	2,903
Rosenbrock	DE current-to-best/1	4,177	2,888	4,283	0,211
Rosenbrock	jDE (adaptive)	4,804	0,399	4,748	4,209
Rosenbrock	DE best/1/bin	5,096	4,773	1,944	1,187
Rosenbrock	Random Search	186,683	101,604	159,462	62,934
Rastrigin	jDE (adaptive)	0,049	0,072	$1,3 \times 10^{-3}$	$5,3 \times 10^{-5}$
Rastrigin	DE current-to-best/1	13,727	8,494	12,110	6,616
Rastrigin	DE best/1/bin	14,408	5,256	13,932	6,259
Rastrigin	DE rand/1/bin	32,034	3,626	32,980	25,959
Rastrigin	DE rand/2/bin	40,980	2,045	40,789	38,228
Rastrigin	Random Search	63,236	7,569	60,691	55,579
Ackley	jDE (adaptive)	$3,0 \times 10^{-6}$	$9,0 \times 10^{-7}$	$3,0 \times 10^{-6}$	$1,9 \times 10^{-6}$
Ackley	DE rand/1/bin	$1,2 \times 10^{-5}$	$6,1 \times 10^{-6}$	$1,1 \times 10^{-5}$	$5,4 \times 10^{-6}$
Ackley	DE rand/2/bin	0,056	$7,2 \times 10^{-3}$	0,055	0,047
Ackley	DE current-to-best/1	0,694	0,633	1,155	$1,4 \times 10^{-4}$
Ackley	DE best/1/bin	3,174	1,500	2,580	2,015
Ackley	Random Search	16,422	1,286	16,757	14,396

Annexe C

Résultats détaillés par graine

Table C.1: Résultats sur le jeu de test pour chaque graine d'entraînement.

Méthode	Graine	AUPRC	AUROC	F1	Précision	Rappel	Seuil
Manuelle (Default)	0	0,1288	0,8433	0,1972	0,1428	0,3183	0,087
Manuelle (Default)	1	0,1250	0,8435	0,2125	0,1663	0,2942	0,089
Manuelle (Default)	2	0,1206	0,8391	0,2012	0,1519	0,2978	0,098
Recherche aléatoire	0	0,1170	0,8280	0,1846	0,1239	0,3619	0,075
Recherche aléatoire	1	0,1190	0,8456	0,1966	0,1672	0,2384	0,104
Recherche aléatoire	2	0,1247	0,8444	0,1772	0,1115	0,4311	0,067
Évolution différentielle	0	0,1178	0,8442	0,1891	0,1400	0,2911	0,081
Évolution différentielle	1	0,1201	0,8383	0,1970	0,1438	0,3126	0,081
Évolution différentielle	2	0,1287	0,8373	0,1819	0,1195	0,3813	0,070

Annexe D

Configuration retenue

Contenu du fichier de configuration `best_hyperparameters.json` :

```
{
  "Default":       {"hidden": 64, "layers": 1, "dropout": 0.2,
                    "lr": 0.001, "wd": 1e-05, "window": 12},
  "Random Search": {"hidden": 63, "layers": 2, "dropout": 0.4813,
                    "lr": 0.000568, "wd": 0.000175, "window": 6},
  "DE":            {"hidden": 98, "layers": 2, "dropout": 0.2548,
                    "lr": 0.002954, "wd": 7.69e-06, "window": 29}
}
```